

FlyGate

도킹 점수에서 나올 수 없는 주장을 잡는 신약 후보 검증 에이전트

대회	NVIDIA x 패스트캠퍼스 Korea Agentic AI Hackathon 2026 온라인 사전 챌린지
팀명	FlyGate
프로젝트	FlyGate
저장소	https://github.com/kakyungkim/korea-agentic-hackathon-2026
생성일	2026-09-27

이 문서의 수치는 모두 저장소의 결과 파일에서 읽어 만들었다. 항목마다 출처 파일을 함께 적는다. 확인하지 못한 것은 확인하지 못했다고 적는다.

1 문제와 해결

해결하고자 했던 문제

안전성 검토자가 감당할 양이 사람 수를 넘었습니다. FDA 이상사례 보고만 2천만 건이 넘고, 그 가운데 어느 것이 약 때문인지 가리는 인과성 평가가 가장 오래 걸립니다. 이 판정은 사람끼리도 잘 맞지 않아, 같은 사례를 두 척도로 평가한 연구에서 일치도가 카파 0.22에 그쳤습니다. 그래서 AI로 덜어 내려는 시도가 이어지는데 도입은 더딥니다. 모델이 내놓은 판단을 무엇과 대조해 믿을지가 비어 있기 때문입니다. 사람 판정이 흔들리니 정답으로 삼기 어렵고, 근거와 숫자가 다 맞는데 결론만 넘어선 주장은 형식 검사로도 걸러지지 않습니다.

서비스 소개와 주요 기능

FlyGate는 근거를 인용한 안전성 주장이 그 근거를 넘어섰는지 가려냅니다. 사람 판정 대신 도구와 데이터 제공자가 문서에 적어둔 경고를 기준으로 삼았습니다. 서로 다른 단백질의 도킹 점수를 견주지 말라거나, 불균형 지표를 인과로 읽지 말라는 문장입니다. 취향이 아니라 만든 쪽이 밝힌 한계이므로 기계가 검사할 수 있습니다. 규칙 열다섯 가지를 그렇게 옮겼습니다. 후보물질 하나를 타깃 단백질에서 사람 근거까지 이어 붙입니다. NVIDIA DiffDock과 AutoDock Vina로 결합을 보고, 실험 친화도를 참조한 뒤, 허가 라벨과 이상사례 보고와 문헌으로 그 후보가 사람에게서 어땠는지 확인합니다. 주장마다 근거 ID가 붙습니다. 크리티크는 세 단계입니다. 1단은 근거 ID를, 2단은 숫자를 원본 로그와 대조하고 둘 다 모델을 쓰지 않습니다. 3단만 모델이 판정합니다. 심어둔 과잉해석 열여섯 건을 모두 반려했고 거짓 양성은 없었습니다. 규칙 없이 모델 판단만 쓰면 열세 건에 그칩니다.

2 파이프라인 구조




그림 1. FlyGate 파이프라인 구조와 크리티크 3단. 모든 실행은 OpenShell 정책 안에서 이루어진다.

크리틱 3단

단	무엇을 보는가	모델을 쓰는가
1단 결정 규칙	주장 존재, 근거 ID 유무, 빈 문자열	쓰지 않는다
2단 숫자 오라클	점수가 원본 로그와 맞는지, SHA256 대조, 지표 재계산	쓰지 않는다
3단 과잉해석 판정	근거와 숫자가 맞아도 추론이 한계를 넘었는지	여기서만 쓴다

같은 케이스에 3단을 돌린 결과

같은 케이스로 근거가 받쳐 주는 요약과 과잉해석 7건을 심은 요약을 나란히 돌렸다. 1단과 2단은 양쪽을 통과시켰고 3단만 갈랐다.

단	근거가 받쳐 주는 요약	과잉해석 7건을 심은 요약
1단 결정 규칙	근거 ID 규칙 통과 = 예	근거 ID 규칙 통과 = 예
2단 숫자 오라클	5/5 일치, 커버리지 83%	5/5 일치, 커버리지 83%
3단 과잉해석 판정	pass	reject
최종 판정	pass	reject

출처 `eval/results/case_niraparib.json`. 3단 판정 모델 `nvidia/nemotron-3-super-120b-a12b`. 과잉해석 규칙은 15종이고 도구 제공자와 데이터 제공자가 문서에 적은 경고에서 옮겼다.

3 검증된 수치

모든 값을 결과 파일에서 읽었다. 출처 파일을 함께 적는다.

적발률 (LLM 판정 포함)

16 / 16

거짓 양성 0 / 17. 평균 점수 0.9697

적발률 (결정 규칙만)

1 / 16

평균 점수 0.0303. 나머지 15건은 근거 ID와 숫자가 전부 맞아 기계 검사를 통과한다

3단이 메운 차이

0.9375

두 적발률의 차이. 같은 케이스와 같은 입력에서 3단만 끄고 켜서 잤다

항목	값	출처 파일
적발률 (LLM 판정 포함)	16/16 , 거짓 양성 0/17, 평균 0.9697	<code>eval/results/critic_verdict_output_llm.json</code>
적발률 (결정 규칙만)	1/16 , 평균 0.0303	<code>eval/results/critic_verdict_output_deterministic.json</code>
평가 케이스	33건	<code>eval/cases.jsonl</code>
과잉해석 규칙	15종	<code>src/harness/tools/overclaim_rules.py</code>
오프라인 테스트	302개 수집	<code>pytest --collect-only -q -m "not network"</code>

항목	값	출처 파일
NAT 등록 도구	8종. <code>echo_tool</code> , <code>prc_calculator</code> , <code>openfda_faers</code> , <code>dailymed_label</code> , <code>pubmed_search</code> , <code>diffdock_nim</code> , <code>vina_reference</code> , <code>bindingdb_ref</code>	<code>configs/author.yml</code>
에이전트 도구 호출	주장 4건 전부 근거 ID 있음. 근거 없는 주장 0건	<code>eval/results/nat_run_author_flydock.json</code>
DiffDock NIM 호출	HTTP 200, 4.1초, 응답 232,461바이트, 포즈 3개	<code>eval/results/diffdock_smoke.txt</code>
샌드박스 스모크	18건 통과, 실패 0건	<code>eval/results/openshell_smoke_flydock.txt</code>
케이스 시연 E2E	Niraparib 두 경로, 7단계 수집, 3단 크리틱 통과와 반려	<code>eval/results/case_niraparib.json</code>

적발률의 분모는 반려가 정답인 케이스 수이고, 거짓 양성성의 분모는 통과가 정답인 케이스 수다. 두 수치는 같은 평가 케이스를 3단만 끄고 켜서 켤 것이라 나란히 놓아야 뜻이 산다. 결정 규칙만으로 돌린 실행에서 나머지 케이스는 `needs_human` 으로 남아 사람에게 넘어간다.

4 케이스 결과




그림 2. Niraparib, 같은 화합물을 두 타겟에 돌린 결과와 크리틱 판정.

항목	경로 A: PARP1 촉매도메인 (4R6E, chain A)	경로 B: 응고인자 Xa (2P16, chain A)
AutoDock Vina 1.2.3 점수	-10.178 kcal/mol	-7.967 kcal/mol
Vina 실행 성격	co-crystal redocking control	Exploratory cross-docking; no claim of validated binding
DiffDock position_confidence	0.761, 0.693, 0.515	-0.172, -0.205, -0.665
BindingDB 참조 집합	있음. 레코드 7,311건, 화합물 5,769종 (UniProt P09874)	없음

두 경로가 함께 쓰는 사람 근거

라벨과 FAERS 와 문헌은 화합물 단위 근거라 두 경로에 같은 값이 온다. 어느 타깃에서 결합했는지를 가리지 못한다.

항목	Niraparib 대 혈소판감소증 (Thrombocytopenia)
허가 라벨 (DailyMed SPL)	기재됨. adverse_reactions, warnings_and_precautions
FAERS 불균형 지표	PRR 9.13 (95% CI 8.61 ~ 9.69), 자료 기준일 2026-07-30
PubMed 문헌	92건
근거의 범위	라벨과 FAERS 와 문헌은 화합물 단위 근거다. 이 타깃에서의 결합을 뒷받침하지 않는다.

두 경로를 가른 것은 점수 차이가 아니라 그 점수를 받쳐 줄 실험 근거의 유무였다. 케이스 브리프는 근거 안의 진술 8항목과 근거 밖의 진술 11항목으로 끝난다. 출처 [eval/results/case_niraparib.json](#) (생성 2026-09-25T07:58:04+00:00). 도킹 원본 SHA256 8d15c55c5c25ddd5...

5 안전과 샌드박스

실행은 NVIDIA OpenShell 안에서만 이루어진다. 정책은 deny-by-default 이고 허용 호스트 7곳만 연다. 쓰기는 지정한 출력 폴더만 허용하며 그 밖의 접근은 차단 로그로 남는다.

항목	값
OpenShell	openshell 0.0.116
정책 파일	<code>policies/flydock.yaml</code>
샌드박스	<code>flydock</code>
유효 정책 해시	<code>06d74bdc4800769ed5d7922082fb0685...</code>
허용 호스트	7곳. <code>health.api.nvidia.com</code> , <code>integrate.api.nvidia.com</code> , <code>files.rcsb.org</code> , <code>drug.flybrain.kr</code> , <code>api.fda.gov</code> , <code>dailymed.nlm.nih.gov</code> , <code>eutils.ncbi.nlm.nih.gov</code>
쓰기 허용 경로	<code>/work/out</code> , <code>/tmp</code> , <code>/dev/null</code>
프로세스 신원	<code>run_as_user=1500</code>

스모크 검증

검증 항목	결과
허용 도메인 (클라이언트: python)	7건 통과
허용 목록 밖(차단되어야 함)	2건 통과
허용 호스트, 정책에 없는 바이너리(curl)	1건 통과
허용 호스트, rules 에 없는 경로 (L7 거부)	1건 통과
파일시스템 쓰기	4건 통과
프로세스 신원 (process.run_as_user)	1건 통과
파이썬 인증서 검증 (https://health.api.nvidia.com/v1/biology/mit/diffdock)	2건 통과
합계	18건 통과, 실패 0건

차단 로그 원문 발췌

허용 목록 밖 호스트, 정책에 없는 바이너리, 정책에 없는 경로가 각각 다른 계층에서 끊긴다. 파일시스템 거부는 커널이 EPERM 으로 끊어 DENIED 줄이 남지 않으므로 Landlock 적용 기록을 함께 싣는다.

```
[1790324728.479] [sandbox] [OCSF ] [ocsf] NET:OPEN [MED] DENIED /usr/bin/python3.12(137) -> example.com:443 [policy:- engine:opa] [reason:endpoint example.com:443 is not allowed by any policy]
[1790324729.584] [sandbox] [OCSF ] [ocsf] NET:OPEN [MED] DENIED /usr/bin/python3.12(150) -> github.com:443 [policy:- engine:opa] [reason:endpoint github.com:443 is not allowed by any policy]
[1790324874.976] [sandbox] [OCSF ] [ocsf] NET:OPEN [MED] DENIED /usr/bin/curl(367) -> integrate.api.nvidia.com:443 [policy:- engine:opa] [reason:binary '/usr/bin/curl' not allowed in policy 'nvidia_inference' (ancestors: [/usr/bin/dash -> /usr/bin/dash -> /opt/openshell/bin/openshell-sandbox], cmdline: [/dev/null, /sandbox]). SYMLINK HINT: the binary path is the kernel-resolved target from /proc/<p...]
[1790324943.052] [sandbox] [OCSF ] [ocsf] HTTP:GET [MED] DENIED GET http://api.fda.gov:443/drug/label.json [policy:openfda engine:l7] [reason:L7_REQUEST deny GET api.fda.gov:443/drug/label.json reason=GET /drug/label.json not permitted by policy]
[1790324948.535] [sandbox] [OCSF ] [ocsf] CONFIG:APPLYING [INFO] Applying Landlock filesystem sandbox [abi:V2 compat:BestEffort ro:12 rw:3]
```

출처 `eval/results/openshell_smoke_flydock.txt`. 각 종류의 첫 줄만 뽑았다. 전문은 저장소의 같은 파일에 있다.

6 기술 스택

NVIDIA Nemotron 3 Super 120B(nvidia/nemotron-3-super-120b-a12b)를 계획과 크리티크 판정에, Nemotron 3.5 Lightning 30B(nvidia/nemotron-3.5-lightning-30b-a3b)를 반복 작업에 씁니다. 두 모델 모두 build.nvidia.com NIM API(OpenAI 호환)로 호출합니다.

NVIDIA DiffDock NIM(health.api.nvidia.com/v1/biology/mit/diffdock)으로 단백질과 리간드의 결합 포즈를 예측합니다. 응답의 신뢰도 값은 포즈 타당성 지표이므로 결합 친화도로 환산하지 않습니다. NVIDIA 문서가 밝힌 한계를 크리티크 규칙에 그대로 넣었습니다.

NVIDIA NeMo Agent Toolkit 1.9.0으로 작성자 워크플로와 크리티크 워크플로를 분리했습니다. 도메인 도구 여덟 종을 NAT 함수로 등록해 에이전트가 직접 호출하고, nat eval로 크리티크 적발률을 측정합니다. 크리티크 워크플로에는 쓰기 도구가 없습니다. NeMo Guardrails 미들웨어로 가드레일 계층을 배선했습니다.

NVIDIA OpenShell 0.0.116으로 실행을 가둡니다. deny-by-default 정책으로 허용 호스트 일곱 곳만 열고, 쓰기는 지정한 출력 폴더만 허용하며, 그 밖의 접근은 차단 로그로 남습니다. 스모크 검증 열여덟 건이 모두 통과했습니다.

build.nvidia.com 스킬 카탈로그의 NVIDIA BioNeMo 에이전트 스킬 `diffdock-nim`을 저장소에 설치해 씁니다(`.claude/skills/nvidia-diffdock-nim/`). DiffDock 도구의 호출 규칙이 그 스킬의 `references/api.md`를 따르고, 신뢰도를 결합 친화도로 환산하지 말라는 과잉해석 규칙도 거기서 옮겼습니다.

그 밖에 Python 3.12, 공개 데이터 소스로 openFDA FAERS, DailyMed SPL, PubMed E-utilities, RCSB PDB를 씁니다. 불균형 지표(PRR, ROR, 신뢰구간, 카이제곱)는 모델이 아니라 파이썬이 계산합니다.

7 미시행 사항

되지 않는 것을 되는 것처럼 쓰지 않는다. 이 저장소의 규율이다.

항목	실제 상태
flybrain_pose	계획. 초파리 커넥톰 포즈 탐색은 아직 도구로 등록하지 않았다
jev_triage	계획. 판정 전용 모델을 싣 분류기로 앞에 두는 구성이다. 호출 규칙이 state 와 questions 형태라 어댑터가 필요하다
NemoGuard 판정 모델	배선까지 했다. 호스팅 쪽 오류로 시연하지 못했다
샌드박스 안 DiffDock 호출	TLS가 닿는 것까지 확인했다. POST는 부르지 않았다
NeMo Retriever 리랭커	이 계정 모델 목록 여든두 개에 없어 쓰지 않았다
NemoClaw	쓰지 않았다. 참조 스택으로 검토만 했다

평가 케이스의 정답 라벨은 저자들이 붙였고 도메인 전문가 두 명 이상의 일치도는 아직 없다. build.nvidia.com 이 간헐적으로 503 을 내므로 측정을 다시 돌려야 할 때가 있다.

8 계보와 기여

주제와 초파리 도킹 경로는 팀원 제안이고, 에이전트 하네스와 검증 체계는 선행 프로젝트 PharmaSignal v0 에서 이어 온 자산입니다. 두 갈래를 하나의 파이프라인으로 이었습니다.

총별 기여

총	내용	기여자	근거
주제와 흑	초파리 커넥툼을 신약개발에 붙이는 발상, 화제성 판단	팀원 A	2026-09-25 팀 논의에서 제안
도킹 자산	FDDD 데모. 타깃 3종, 화합물 6종, AutoDock Vina 1.2.3 실행 8건, 수용체와 포즈와 로그의 SHA256, BindingDB 참조, DailyMed PK	팀원 A	drug.flybrain.kr, docs/notes/fddd-and-jev.md
해석 한계 목록	하지 말아야 할 해석 8항목. 우리 크리틱 규칙의 뼈대가 됨	팀원 A	FDDD multi-target.json 의 notes 배열
Jev 접목 제안	판단 전용 모델을 파이프라인에 얹는 구성	팀원 A	공유된 아키텍처 도식을 보고 제안
약 도메인 검토	라벨 읽기, 약 정보 정합, 약사 관점	팀원 B	
NAT 하네스	작성자과 크리틱 분리, 근거 ID 검증 구조, 도메인 중립 코어 약 500줄	팀장	src/harness/
약물감시 도구	openFDA FAERS 집계와 불균형 지표, DailyMed 라벨 섹션, PubMed 문헌, ROR 오라클	팀장	src/harness/tools/pharmasignal_*.py
샌드박스	OpenShell 정책과 차단 로그, provider profile 자격증명 격리	팀장	policies/, eval/results/openshell_smoke*.txt
평가 체계	nat eval 적발률, 크리틱 판정 평가기	팀장	src/harness/evaluators.py
NIM 통합	생물학 NIM 접근 확인과 호출 계층, DiffDock 도구	팀장	docs/notes/bionemo-nim.md, eval/results/diffdock_smoke.txt
과잉해석 크리틱	규칙 15종과 부정 케이스, 3단 판정	팀장 설계, 팀원 A 의 목록을 출처로	docs/notes/topic-decision.md 규칙 표
제작 파이프라인	영상 9단계, 이중언어 슬라이드, 그림 생성	팀장	assets/, scripts/make_figures.py

외부 자산과 라이선스

자산	출처	라이선스
AutoDock Vina 실행 결과와 준비된 수용체	Durrant Lab webina, MolModa	해당 저장소 표기를 따름
수용체 구조 4R6E, 2P16, 3LN1	RCSB PDB	공개
BindingDB 참조 친화도	BindingDB REST	해당 사이트 표기를 따름
NVIDIA BioNeMo 에이전트 스킵 문서	NVIDIA-BioNeMo/bionemo-agent-toolkit	문서 CC-BY-4.0, 코드 Apache-2.0. 출처 표기 필요
Pretendard 폰트	orioncactus/pretendard	OFL
초파리 커넥툼	MaleCNS, FlyWire	각 배포처 표기를 따름

초파리 도킹 자산 FDDD 는 팀원의 별도 저작물이다. 복제하지 않고 도구로 참조하며 데이터 출처와 SHA256 을 그대로 인용한다. 공개 산출물에는 실명을 쓰지 않고 역할로만 적는다. 출처 `docs/notes/credits.md`.

9 교육 미션

수료증 이미지를 여기에 넣는다

NVIDIA DLI S-FX-43 Securing Agents with OpenShell and NemoClaw

아직 수료 전이라 비워 둔다. 수료 후 `scripts/make_submission_pdf.py` 의 `CERT_IMAGE` 에 이미지 경로를 넣고 다시 만든다.

과정 주소는 `https://learn.nvidia.com/courses/course-detail?course\_id=course-v1:DLI+S-FX-43+V1` 이다. 레슨 1a와 1b를 들었다. 모듈 3과 4는 Brev 인스턴스를 띄워야 진도가 오른다. 원격 진도 기록은 기본으로 꺼져 있으니 도구 모음의 Activity에서 켜다. 수강 안내는 `docs/COURSE-GUIDE.md` 에 있다. 수료 전이므로 수료 사실을 적지 않는다.